

국내 금융회사 개인정보처리방침 준수 여부 자동 검토

PDF OCR · 자동평가 · EDA ·
Streamlit · RAG 확장 프로토타입

분석 대상 122개사 · 24개 체크리스트 · OCR 122/122 · 자동평가 완료
개인정보보호위원회 「개인정보 처리방침 작성지침('26.4월 기준)」 기반

프로젝트 개요

항목	내용
분석 대상	국내 금융회사 개인정보처리방침 122개사
분석 기준	개인정보보호위원회 「개인정보 처리방침 작성지침('26.4월 기준)」 기반 24개 체크리스트
분석 방법	PDF OCR · 텍스트 정제 · threshold 기반 자동평가 · EDA · Streamlit 시각화
확장 기능	JSON 구조화 · ChromaDB · VectorDB · OpenAI API 기반 RAG 질의응답 프로토타입
GitHub	github.com/miracleharuforall/fun1-20260524
Streamlit	fun1-20260524.streamlit.app

AGENDA

발표 순서

프로젝트 개요부터 결과·인사이트·확장 설계까지 6개 구간으로 안내드립니다.

PART 01 — WHY

왜 이 분석인가

1. 프로젝트 개요
2. 선정 이유 · 연구 질문
3. 전체 처리 흐름

PART 02 — DATA

데이터 수집 · 전처리

4. 122개사 수집 결과
5. PDF OCR · 노이즈 제거
6. JSON 구조화

PART 03 — METHOD

자동평가 방법

7. 24개 체크리스트 설계
8. requirement_type 구분
9. threshold 기반 채점

PART 04 — EDA

탐색적 데이터 분석

10. 핵심 지표
11. 업권별 · 필수항목 비교
12. 누락 · 히트맵 · 투명성

PART 05 — INSIGHT & TOOLING

주요 인사이트 · Streamlit 대시보드 · RAG 질의응답

13. 주요 인사이트 · 14. Streamlit 대시보드 · 15. RAG 질의응답 프로토타입

PART 06 — EXTEND

확장 설계 · LDA 이론 · 한계와 향후 개선

16. AWS 인프라 확장 · 17. LDA 이론 소개 · 18. 한계 · 19. 마무리

1. 프로젝트 개요

“개인정보처리방침”을 데이터로 검증한다

국내 122개 금융회사 개인정보처리방침을 PDF에서 자동 수집·OCR·자동평가·시각화하고, JSON·VectorDB·OpenAI API 기반 RAG 질의응답 프로토타입까지 구성하였습니다.

1.1 프로젝트 주제

금융회사 홈페이지의 PDF 처리방침을 자동 수집·OCR·평가

개인정보보호위원회 「개인정보 처리방침 작성지침(’26.4월 기준)」 주요 기재사항을 기준으로 자동 평가 및 EDA를 수행, Streamlit 대시보드와 JSON·ChromaDB·VectorDB·OpenAI API 기반 RAG 질의응답 프로토타입으로 확장 구성하였습니다.

1.2 선정 이유

금융회사 개인정보처리방침의 주요 기재사항 검토 효율화

금융회사는 민감하고 중요한 개인정보를 대규모로 처리하며, 개인정보처리방침은 정보주체가 개인정보의 수집·이용·제공·보관·파기 내용을 확인할 수 있는 핵심 공개문서입니다.

특히 중소형 금융회사나 인력이 제한된 조직에서는 보안·개인정보보호·전산·준법 업무를 소수 인력이 겸직하는 경우가 많아, 주요 기재사항을 효율적으로 점검할 수 있는 방법이 필요합니다.

이에 공개 문서인 개인정보처리방침을 OCR·텍스트 정제·키워드 기반 자동평가로 분석하여, 반복 가능한 자동 점검 가능성을 검토하고자 했습니다.

이 분석이 답하고자 하는 것

[A] 점검 효율화

개인정보처리방침 주요 기재사항을
반복 가능하게 자동 점검

[B] 개선점 도출

작성지침 대비
업권·항목별 기재 수준의 차이 확인

[C] 확장 가능성

JSON·VectorDB·LLM 연계를 통한
RAG 기반 점검 서비스 확장

1.3 연구 질문

5개의 연구 질문이 분석을 이끌었습니다

Q1.

국내 금융회사 처리방침은 작성지침의 주요 기재사항을 얼마나 충족하는가?

— 전체 평균 준수율 · 필수항목 준수율 등 거시 지표

Q2.

금융회사 업권별 처리방침의 기재 수준에 차이가 있는가?

— 은행 · 금융투자 · 보험 · 중소서민 등 9개 업권 비교

Q3.

어떤 작성지침 항목이 가장 자주 누락되거나 낮게 기재되는가?

— 24개 체크리스트 항목별 누락률 · 항목별 충족률

Q4.

국외이전 · 가명정보 · 자동 의사결정 · 제3자 행태정보 등 디지털 신기능 항목 공개 수준은?

— 디지털 투명성 지표 vs 정보주체 권리보장 지표

Q5.

정제된 개인정보처리방침 데이터를 JSON · VectorDB로 확장하여 자연어 기반 질의응답으로 활용할 수 있는가?

— RAG 도입 목적, 처리 흐름, Streamlit Cloud 제약 사항


분석의 시사점 ▶ 데이터 기반 점검 · 개선 + LLM 연계 자연어 RAG 점검 서비스 — 두 갈래로 결과를 활용합니다.

1.4 프로젝트 전체 처리 흐름

분석 파이프라인 + RAG 확장 파이프라인

| 전체 분석 파이프라인

금융사 처리방침 PDF를 수집 → OCR · 정제 · 자동평가 · EDA · Streamlit 시각화의 순서로 진행하였습니다.



| RAG 확장 파이프라인

정제된 텍스트를 JSON · chunk로 구조화 후, VectorDB와 OpenAI API를 통해 자연어 질의응답 프로토타입으로 확장합니다.



산출물 ①

정제 텍스트 122건
clean_text_v3 + JSON 구조

산출물 ②

자동평가 결과 매트릭스
122 × 24 항목, CSV/XLSX

산출물 ③

Streamlit 대시보드
6개 메뉴 · 회사별 조회

산출물 ④

RAG 질의응답
로컬 프로토타입

2. 데이터 수집 결과

130개 수집 → 122개 최종 분석 대상 확정

OCR 정제 후 텍스트 길이 1,000자 미만 8개사를 제외, 최종 122개 금융회사를 분석 대상으로 확정하였습니다.

최초 PDF 수집

130

금융회사 홈페이지 Print > PDF 방식

OCR 및 텍스트 정제

130

Tesseract OCR · 정규표현식 기반

제외 분석

8

텍스트 1,000자 미만 PDF 제외

최종 분석 대상

122

업권 분류 및 자동평가 진행

2.3 개인정보처리방침 URL 관리 — 마스터 파일 185개 → 회사 단위 122개로 매핑

출처 재현성을 확보하기 위해 처리방침 URL과 정제 텍스트를 분리 관리. URL 마스터 파일(185개)에서 회사 단위로 통합한 결과, 최종 122개 회사 URL을 companies.csv에 매핑(마스터 기준 Print > PDF 방식으로 저장 불가했던 55개사 + OCR 정제 텍스트 1,000자 미만 8개사는 분석 대상에서 제외).

파일명	역할
policy_url_master_185.xlsx	금융회사별 개인정보처리방침 URL 마스터
policy_url_merge_check.xlsx	URL 병합 검토 파일
companies.csv	최종 분석 대상 122개 회사의 업권, 파일명, URL 정보

2.2 업권 분류

122개 금융회사를 9개 업권으로 분류

업권 분류는 업권별 평균 준수율, 필수항목 준수율, 디지털 투명성 지표 · 정보주체 권리보장 지표를 비교하기 위한 기준 변수로 사용합니다.

업권	분류 기준 (법적 근거)
은행	「은행법」에 따른 은행 · 「한국산업은행법」 · 「중소기업은행법」 · 「농업협동조합법」 · 「수산업협동조합법」에 따른 신용사업부문
금융투자	「자본시장과 금융투자업에 관한 법률」에 따른 금융투자업자 · 종합금융회사
보험	「보험업법」에 따른 보험회사
금융유관기관	사단법인 금융결제원 · 「자본시장과 금융투자업에 관한 법률」에 따른 한국예탁결제원 · 한국거래소 · 증권금융회사 · 주식회사 코스콤 · 「신용정보의 이용 및 보호에 관한 법률」에 따른 신용정보 집중기관
중소서민	여신전문금융회사 · 새마을금고 · 농협중앙회의 신용사업부문 · 상호저축은행 · 신용협동조합 · 산림조합 · 「신용보증기금법」에 따른 신용보증기금회사
가상자산사업자	「가상자산 이용자 보호 등에 관한 법률」 및 「특정금융정보의 보고 및 이용 등에 관한 법률」에 따른 가상자산사업자
전자금융업	「전자금융거래법」에 따른 전자금융업자
핀테크	금융 플랫폼 · 마이데이터 · 간편 금융서비스 등 기술 기반 금융서비스를 제공하는 회사
보험GA	보험상품의 판매 · 모집 업무를 수행하는 법인보험대리점 또는 보험대리점 관련 업권

3. 데이터 전처리

OCR → 노이즈 제거 → 결측·이상치 → JSON

3.1 PDF OCR 추출

Tesseract OCR + Poppler

PDF 문서는 금융사별로 형태와 품질이 다르므로, 일반 PDF 텍스트 추출 방식으로는 모든 문서에 안정적으로 처리되지 않습니다.

따라서 OCR 기반 추출 방식을 사용해 모든 PDF를 이미지 기반 OCR로 처리하였습니다.

extract_pdf_ocr.py 실행 → 122개 PDF가 OCR로 변환되어 **processed_policies_ocr.csv**에 저장.

3.2 OCR 노이즈 제거 — clean_text_v3

웹사이트 메뉴 · 페이지 이동 문구 · URL · 반복 공백 · 깨진 문자 제거

대상 PDF 수	평균 정제 길이	최소 정제 길이	최대 정제 길이
122개	10,837자	3,060자	31,987자

정규표현식 기반 불필요 문구 제거 → 분석에 필요한 본문 중심 **clean_text_v3**

3.3 결측치 및 이상치 처리

품질 기준은 OCR 정제 후 텍스트 길이

정제 후 텍스트가 1,000자 미만인 문서는 처리방침의 본문이 충분히 추출되지 않았다고 보고, 신뢰도가 낮다고 판단하여 제외하였습니다. 이 과정을 통해 최초 130건 문서에서 최종 122개 문서로 분석 표본을 확정하였습니다.

처리 항목	처리 방식	이유
텍스트 길이 1,000자 미만	본문 대상에서 제외	본문 추출 부족으로 자동평가가 신뢰도 저하 가능
URL 결측	URL 마스터와 병합하여 보완	출처 재현성 확보
OCR 노이즈	정규표현식 기반 제거	키워드 매칭 정확도 개선
조건부 항목 미기재	법 위반으로 단정하지 않음	실제 해당 처리 여부 확인 필요

3.4 PDF 텍스트의 JSON 구조화

회사 단위 통합 메타데이터

RAG 질의응답 확장을 위해 CSV/XLSX 기반 결과를 회사별 JSON으로 재구조화. 회사명·업권·PDF·정제 텍스트·체크리스트 평가·매칭 키워드까지 포함.

```
{
  "company_name": "AIA생명보험",
  "sector": "보험",
  "file_name": "AIA생명보험.pdf",
  "policy_url": "https://...",
  "clean_text": "개인정보처리방침 본문...",
  "checklist_results": [
    { "item_id": "C01", "score": 1, ... }
  ],
  "metadata": { "text_length": 23859 }
}
```


4.1 24개 체크리스트 구성

작성지침 기반 24개 평가 항목 (C01-C24)

각 항목은 로 구성되며, 텍스트에서 관련 키워드가 일정 기준 이상 발견되면 해당 항목을 충족한 것으로 판정합니다.

item_id · item_name · requirement_type · 평가 키워드 · 최소 매칭 수

CHECKLIST FIELDS

체크리스트 필드 구성

컬럼	설명
item_id	체크리스트 항목 ID (C01-C24)
item_name	체크리스트 항목명
requirement_type	required / conditional / recommended / conditional_recommended
regex_keywords	자동평가에 사용되는 키워드 또는 정규표현식
min_match_count	충족 판정을 위한 최소 매칭 수

make_checklist_v2.py 실행 결과

checklist.csv 생성 완료

```
item_id min_match_count
C01 처리 목적 1
C02 개인정보 항목 2
C03 처리 및 보유 기간 1
C14 14세 미만 아동의 ... 2
... (총 24개 항목 자동 생성)
```

24 ITEMS · checklist.csv

자동평가 24개 체크리스트 (요약)

- C01 처리 목적
- C02 개인정보 항목
- C03 처리 및 보유 기간
- C04 14세 미만 아동의 개인정보 처리
- C05 개인정보 파기 절차 및 방법
- C06 개인정보 제3자 제공
- C07 개인정보 처리 위탁
- C08 개인정보 국외 이전
- C09 가명정보 처리
- C10 추가적인 이용·제공의 판단 기준
- C11 민감정보 공개 가능성 및 비공개 방법
- C12 이동형 영상정보 처리기기 운영·관리
- C13 고정형 영상정보 처리기기 운영·관리
- C14 정보주체와 법정대리인의 권리·의무
- C15 제3자 행태정보 수집·이용·제공·거부
- C16 자동화된 결정 등 조건부
- C17 개인정보 안전성 확보 조치
- C18 개인정보 보호책임자
- C19 국내 대리인 지정
- C20 개인정보 열람·정정·삭제·처리정지 요구
- C21 권익침해 구제 방법
- C22 개인정보 처리방침 변경 사항 등
- C23 정보주체 추가 권리
- C24 개인정보 자율규제 단체

4.2~4.3 requirement_type 구분 · threshold 자동평가

“키워드가 N번 이상 등장하면 충족”

4.2 requirement_type 4개 구분 — 항목의 법적 성격에 따라 해석을 달리합니다

required

필수 성격의 기본 기재사항

기본 고지사항의 충족 수준을 직접적으로 해석 가능

conditional

해당 처리를 수행하는 경우 기재

미기재를 곧바로 법 위반으로 해석하지 않음

recommended

투명성 강화를 위한 권장 항목

문서 품질과 투명성 수준을 보조적으로 해석

conditional_recommended

해당시 권장사항

실제 해당 여부 확인 필요

4.3 threshold 기반 자동평가 방식

CORE LOGIC

$\text{matched_count} \geq \text{min_match_count} \Rightarrow \text{충족}(1)$

```
if matched_count >= min_match_count:
    score = 1
else:
    score = 0
```

⚠ 한계점 키워드 빈도 기반이므로 문맥적 의미를 완전히 반영하지 못합니다.
실제 평가에서는 해석 시 주의가 필요합니다.

집계 공식

4가지 파생 지표

■ 회사별 전체 준수율

= 충족 항목 수 ÷ 전체 체크리스트 항목 수 × 100

■ 업권별 평균 준수율

= 동일 업권 회사들의 회사별 준수율 평균

■ 업권별 필수항목 준수율

= required 항목 중 충족 ÷ required 전체 × 100


■ 항목별 누락률

= 해당 항목 미충족 회사 수 ÷ 전체 회사 수 × 100


5. 탐색적 데이터 분석 (EDA) · 핵심 지표

한 화면에 정리한 분석 결과

122개 회사 · 24개 체크리스트 기준 · 전체 평균 준수율 54.5% · 필수항목 준수율 82.0%로 요약됩니다.



| requirement_type별 충족률 — 항목 성격에 따라 충족 수준이 크게 달라집니다



해석 required는 모든 회사에 일률적으로 적용되지만, conditional·conditional_recommended는 실제 해당하지 않으면 미충족 처리 → 낮은 충족률을 곧바로 법 위반으로 해석하지 않습니다.

5.3 업권별 종합 비교

9개 업권 × 4개 지표

전체 평균 준수율, 필수항목 준수율, 디지털 투명성 지표, 정보주체 권리보장 지표를 업권별로 비교한 결과 — 모든 업권에서 필수항목 준수율이 전체 평균보다 높음.

■ 전체 평균 준수율 ■ 필수항목 준수율 ■ 디지털 투명성 지표 ■ 정보주체 권리보장 지표

업권	회사 수	● 전체 평균	● 필수항목	● 디지털 투명성	● 정보주체 권리보장
은행	60	67.9	88.0	60.0	80.8
가상자산사업자	3	80.7	88.9	77.8	46.7
금융투자	17	57.8	88.2	46.0	72.5
금융유관기관	4	57.2	88.9	30.0	65.7
핀테크	7	54.2	85.7	71.4	34.3
중소서민	36	53.0	80.2	31.5	64.4
보험	23	51.6	77.8	34.8	70.3
보험GA	—	51.8	84.1	14.2	66.7
전자금융업	12	44.1	72.2	26.7	56.9

시사점 ①

기본 필수 기재사항은 안정적

대부분의 업권에서 필수항목 준수율 ≥ 전체 평균. 처리목적·항목·보유기간·파기·보호책임자 등 기본 항목은 비교적 충실히 반영.

시사점 ②

해당시·권장 항목까지 보면 격차 확대

디지털 투명성에서 보험GA 14.2% · 전자금융업 26.7% 등 편차 큼. 신기능 항목 반영도가 업권 간 격차의 핵심 원인.

5.4 업권별 필수항목 준수율

9개 업권 모두 전체 평균(54.5%) 대비 높음

required 항목만 대상으로 산정한 업권별 평균은 금융유관기관·가상자산사업자(88.9%)가 가장 높고 전자금융업(72.2%)이 가장 낮습니다. 전체 24개 기준 평균(54.5%)보다 법정 필수 성격의 기본 기재 수준이 더 정확하게 반영됩니다.

그림 12. 업권별 필수항목 준수율 그래프

required 항목만 산정 · 9개 업권 (단위: %)



시사점 모든 업권이 전체 평균(54.5%)을 큰 폭으로 상회 — 필수 기재사항은 비교적 안정적이지만, 해당시·권장 항목까지 포함한 전체 기재 수준은 구분해 해석해야 합니다.

5.5 requirement_type별 충족률

필수항목 82% vs 조건부 38% — 큰 격차

체크리스트 항목을 기재 성격에 따라 4개 유형으로 구분, 충족 수준을 비교한 결과입니다. 낮은 충족률을 곧바로 법 위반으로 해석하기보다 공개된 처리방침상 명시 여부가 낮은 항목으로 해석하는 것이 타당합니다.

기재 유형별 충족률

required가 가장 높고 conditional_recommended가 가장 낮음

required 82.0%

recommended 54.9%

conditional 38.1%

conditional_recommended 4.1%

통계표 · pass_count / total_count / pass_rate / missing_rate

유형별 상세 통계


requirement_type	pass	total	pass_rate	missing_rate
required	900	1,098	82.0	18.0
recommended	134	244	54.9	45.1
conditional	558	1,464	38.1	61.9
cond_recommended	5	122	4.1	95.9

해석 required는 금융회사 공통의 기본 기재사항으로 가장 높은 충족률. conditional은 실제 해당 개인정보 처리를 수행하는 경우에만 기재하므로 상대적으로 낮은 수치는 정상. 결론 낮은 충족률은 곧바로 법 위반이 아니라, 공개된 처리방침의 명시 여부가 낮은 항목으로 해석하는 것이 타당합니다.

5.6 체크리스트 항목별 누락률

누락률 TOP 3 — 모두 조건부·신기능 항목

누락률은 국내대리인 지정·이동형 영상정보처리기기·자동화된 결정 등 조건부 항목에서 높게 나타납니다. 실제 미준수라기보다 해당 처리 여부가 있는 경우에만 기재되는 항목의 특성이 반영된 결과입니다.



전체 24개 항목 누락률 (높은 순)

조건부·신기능 항목이 상위권을 차지

ID	항목명	requirement_type	누락률	비고
C22	이동형 영상정보처리기기 운영·관리	conditional	100.0%	전 회사 미기재
C19	국내대리인 지정	cond_recommended	95.9%	해당 사업자만 기재
C12	영상정보처리기기 (고정형) 운영·관리	conditional	95.1%	해당 시 기재
C13	제3자 행태정보 수집·이용·제공·거부	conditional	90.2%	온라인 마케팅 관련
C15	자동화된 결정 등 조건부 항목	conditional	83.6%	디지털 신기능 항목
... 전체 24개 항목 ...				
C01	처리 목적	required	0.0%	전 회사 기재 (만점)

5.7 업권 × 체크리스트 항목 히트맵

어떤 업권의 어떤 항목이 낮은 지 한눈에

색이 진할수록 충족률이 높고, 옅을수록 낮다는 의미입니다. 분석 결과 기본 필수항목 영역(C01·C02·C17·C18 등)에서 대부분 업권이 상대적으로 높은 충족률을 보이며, 국외이전·제3자 행태정보·자동화된 결정·영상정보처리기기 등 조건부·디지털 신기능 항목에서 업권 간 편차가 크게 나타납니다.

그림 15. 업권 × 체크리스트 항목 히트맵

짙은 색 = 충족률 높음 · 옅은 색 = 충족률 낮음

	C01 처리목적	C02 항목	C08 국외이전	C12 영상(고정)	C13 행태정보	C15 자동결정	C17 안전성	C18 보호책임자	C19 국내대리인	C22 영상(이동)
은행										
금융투자										
보험										
가상자산										
중소서민										
전자금융업										
핀테크										

□ 0~20% □ 20~40% □ 40~70% □ 70~100

패턴 1 좌측(기본 필수항목)은 전 업권 진한 색 — 안정적 반영 | 패턴 2 우측(영상·신기능·국내대리인)으로 갈수록 옅어짐 — 업권 간 격차 시사점 디지털 환경 또는 특정 개인정보 처리 활동과 관련된 항목에서 업권별 명시 수준에 다양한 양상이 존재합니다.

5.8 디지털 투명성 vs 정보주체 권리보장

두 파생지표의 균형 — 업권별로 다른 양상

디지털 투명성 지표 = C10·C13·C14·C15·C17 / 정보주체 권리보장 지표 = C14·C16·C17·C18·C20·C24
디지털 환경의 처리 투명성 vs 권리·자동결정 등 권리보장 영역을 동시에 비교합니다.

디지털 투명성 지표

국외이전 · 가명정보 · 자동의사결정 · 제3자 행태정보 · 자동화된 결정 거부

디지털 환경의 개인정보 처리 공개 수준

정보주체 권리보장 지표

국외이전 / 가명정보 / 자동의사결정 거부 / 보호책임자 / 권익침해 구제 / 처리방침 변경 관리

권리·민원·구제 절차의 명시 수준

그림 16. 디지털 투명성 vs 정보주체 권리보장 버블차트 (보고서 데이터)

업권	디지털 투명성 지표	정보주체 권리보장 지표	해석
은행	60.0	80.8	두 지표 모두 균형 — 모범 사례
가상자산사업자	77.8	46.7	디지털 투명성 우수, 권리보장 보완
핀테크	71.4	34.3	신기능 강세, 권리·구제 보완 필요
금융투자	46.0	72.5	권리보장 강세, 신기능 보완 필요
보험	34.8	70.3	전통적 권리보장 ↑ 신기능 ↓
금융유관기관	30.0	65.7	안정적 권리보장, 디지털 신기능 보완
중소서민	31.5	64.4	두 지표 모두 평균~중하 수준
전자금융업	26.7	56.9	두 지표 모두 하위권 — 보완 필요
보험GA	14.2	66.7	디지털 투명성 매우 낮음

시사점 기본적인 권리안내는 상대적으로 잘 기재되었으나, 디지털 신기능 항목 공개 수준은 업권별 추가 개선 여지가 있습니다. · 그림 16. 버블차트

6. 주요 인사이트

분석에서 얻은 4가지 핵심 결론

INSIGHT 01

필수항목은 비교적 안정적으로 기재 (82.0%)

required 항목 충족률은 82.0%로 가장 높습니다. 개인정보 처리 목적, 처리 항목, 보유기간, 파기, 보호책임자 등 기본 필수항목은 대부분의 금융회사 처리방침에 비교적 충실히 기재되어 있습니다.

INSIGHT 02

전체 평균(54.5%) 저하 요인은 해당 시·권장 항목

conditional · recommended · conditional_recommended 항목이 포함되어 전체 평균이 낮아진 것이며, 이는 실제 평가에서 conditional 항목이 포함된 결과 때문입니다.

INSIGHT 03

디지털 신기능 관련 공개 수준은 업권별 상대적으로 낮음

국외이전 · 가명정보 · 자동화된 결정 · 제3자 행태정보 등 디지털 환경 관련 항목은 업권별 명시 수준에 큰 격차를 보입니다. 안내가 모호하거나 누락된 사례가 발견됩니다.

INSIGHT 04

조건부 항목 누락은 해석에 주의 필요

조건부 항목은 해당 처리를 수행하지 않으면 미충족(0)으로 나타나지만, 이는 처리방침상 명시 여부가 낮은 항목일 뿐 법 위반은 아닙니다. 별도 확인이 필요합니다.

▶ 다음 단계 — 분석 결과를 Streamlit 대시보드와 RAG 질의응답 프로토타입으로 활용성 확장

7. Streamlit 대시보드 구현

분석 결과를 누구나 확인 가능한 인터랙티브 대시보드로

좌측 메뉴를 클릭하면 프로젝트 개요, 핵심 지표, 회사별 상세 등 6개 화면으로 이동합니다. URL: fun1-20260524.streamlit.app

01

프로젝트 개요

연구 질문, 데이터 수집 및 전처리 흐름

02

핵심 지표

122개 분석 대상, 24개 체크리스트, 전체 평균 준수율, 필수항목 충족률

03

분석 결과

6개 핵심 EDA 시각화 화면

04

회사별 상세 조회

회사별 URL, 업권, 평가 요약, 항목별 상세 평가 제공

05

RAG 질의응답

로컬 VectorDB 기반 RAG 프로토타입 안내 (Cloud 배포는 제한)

06

한계 및 결과

주요 인사이트와 분석 한계 정리

그림 18. 회사별 상세 조회 화면

회사별로 — URL · 업권 · 평가 요약 · 24개 항목별 상세 평가 제공

각 항목별 `item_id` · `item_name` · `requirement_type` · `score` · `matched_count` · `min_match_count` · `matched_keywords`가 표시되어, 어떤 키워드가 어떤 항목과 매칭되어 충족 판정이 났는지 추적 가능함
AIA생명보험 → 보험 → checked → AIA생명보험.pdf)

8. RAG 질의응답 프로토타입

그래프·표를 넘어 자연어 질의응답으로 확장

8.1 도입 목적

사용자가 자연어로 직접 확인

기존 대시보드는 그래프와 표를 통해 사용자가 분석 결과를 직접 확인하는 구조입니다.

RAG는 사용자가 자연어로 질문하면 관련 처리방침 문서 조각을 검색하고, OpenAI API를 통해 근거 기반 답변을 생성합니다.

24개 체크리스트 자동평가가 결과를 대체하는 것이 아니라, 정제된 처리방침 문서를 자연어로 탐색하기 위한 보조적 확장입니다.

8.2 RAG 처리 흐름

7단계 처리 흐름

- ① 정제 텍스트 → ② 회사별 JSON 변환
- ③ 문서 chunk 분할 → ④ 한국어 문장 임베딩 생성
- ⑤ ChromaDB VectorDB 저장 → ⑥ 사용자 자연어 검색
- ⑦ OpenAI API 기반 답변 생성

8.3 구현 범위

로컬 환경 RAG 프로토타입 — Streamlit Cloud 배포본은 안내문만 제공

Streamlit Cloud는 VectorDB 파일을 포함하지 않으므로, 로컬에서는 정상 실행되지만 배포본에서는 안내 문구만 표시됩니다.

구분	구현 여부	설명
JSON 변환	구현	정제 텍스트와 평가 결과를 회사별 JSON으로 구조화
Chunk 생성	구현	긴 개인정보처리방침을 검색 가능한 문서 조각으로 분할
VectorDB 구축	구현	ChromaDB에 임베딩과 메타데이터 저장
OpenAI API 연동	구현	검색된 근거 기반 자연어 답변 생성
Streamlit Cloud RAG 실행	제한	VectorDB 파일 미포함 → Cloud에서는 안내 메시지 제공

9. AWS 인프라 구성 및 확장 설계

로컬 분석을 AWS 기반 운영 서비스로 확장

본 프로젝트는 로컬 Python + Streamlit Community Cloud 기반으로 구현. 실제 운영 환경에서는 AWS 운영 서비스로 확장 시 PDF 저장, OCR/전처리 실행, 분석 결과 저장, VectorDB 검색, LLM 질의응답까지 일관된 아키텍처로 구성 가능합니다.

구성 요소	AWS 서비스 예시	역할
PDF 및 JSON 저장	Amazon S3	PDF 원본, JSON 분석 결과 저장
OCR / 전처리 실행	EC2 또는 AWS Lambda	OCR, 텍스트 정제, JSON·chunk 생성
분석 결과 저장	Amazon RDS	평가 결과, EDA 결과 저장
VectorDB	OpenSearch Vector Engine 또는 RDS PostgreSQL pgvector	문서 임베딩 저장 및 검색
LLM 연동	Amazon Bedrock 또는 OpenAI API	자연어 질의응답 생성
대시보드	Streamlit on EC2 또는 Streamlit Cloud	사용자 화면 제공
모니터링	Amazon CloudWatch	실행 로그 및 운영 모니터링

그림 21. AWS 기반 확장 아키텍처

단방향 흐름으로 표현된 운영 파이프라인



10. LDA 이론 소개

매칭 이론 — LDA(Latent Dirichlet Allocation)

본 절의 LDA는 본 프로젝트에서 실제 모델링 결과를 산출한 분석 단계가 아니라, 교수님 매칭 이론에 따라 개인정보처리방침 분석에 적용 가능한 이론적 확장 방향으로 제시한 내용입니다.

10.1 LDA(Latent Dirichlet Allocation) 개요

문서를 여러 잠재 토픽의 혼합으로 표현하는 확률적 토픽 모델링

여러 문서 안에서 자주 함께 등장하는 단어 집합(topic)을 자동으로 찾아내는 대표적 토픽 모델링 기법 → 하나의 문서에는 여러 토픽이 섞여 있고, 하나의 토픽은 단어의 확률분포로 구성됩니다.

10.2 개인정보처리방침 분석과의 연결 — 122개 금융사 처리방침을 LDA로 토픽 분류 시 추정 결과

LDA 토픽 예시	개인정보처리방침 내 의미
Topic 1. 수집·이용 목적	개인정보 수집 목적 및 이용 목적 관련 문단
Topic 2. 제3자 제공 및 위탁	제공받는 자, 위탁업무, 수탁자 관련 문단
Topic 3. 국외이전 및 클라우드	해외 이전, 국외 처리, 클라우드 인프라 관련 문단
Topic 4. 권리행사·자동결정·집행	쿠키, 접속기록, 행태정보 관련 문단
Topic 5. 정보주체 권리행사·보호책임자	권리행사 방법, 보호책임자, 구제방법 관련 문단

파이프라인 흐름 처리방침 텍스트(122개) → OCR 정제 `clean_text_v3` → 문서·단어 매트릭스 Document Term Matrix → LDA 모델 학습 → 토픽 자동 분류·시각화
체크리스트 평가가 사전에 정한 기준으로 충족 여부를 판단한다면, LDA는 문서 자체에서 반복되는 주제를 자동으로 식별 — 두 방법을 함께 사용하면 처리방침의 준수 수준과 내용 특징을 동시에 분석할 수 있습니다.

11. 한계 및 향후 개선방안

솔직한 한계 인식 + 구체적 개선 로드맵

11.1 분석 한계

현재 분석의 5가지 제약

① OCR 기반 분석

PDF 품질에 따라 일부 텍스트 추출 오류 발생 가능

② 키워드 빈도 / threshold 기반 자동평가

문맥 의미를 완전히 반영하기 어려움

③ 조건부 항목은 실제 해당 개인정보 처리 여부 확인 불가

낮은 기재율을 곧바로 법 위반으로 해석할 수 없음

④ RAG 답변은 VectorDB에서 검색된 문서 조각 기반

검색 근거에 없는 내용은 답변할 수 없음

⑤ Streamlit Cloud 배포본 제약

VectorDB 파일 미포함으로 RAG 기능이 제한됨

11.2 향후 개선방안

5단계 발전 로드맵

- 1 OCR 품질 개선 및 원문 PDF 페이지 단위 검증 자동화
추출 오류율 자동 검출 및 보정
- 2 LLM 기반 문맥 평가 / 체크리스트 판정 보강
키워드 매칭의 문맥적 한계 극복
- 3 LDA 또는 BERTopic 기반 토픽 자동 분류 추가
사전 정의되지 않은 주제 패턴 발견
- 4 AWS S3 · OpenSearch Vector Engine · Bedrock 기반 운영 RAG 구조 확장
로컬 프로토타입 → 운영 서비스 전환
- 5 업권별 표본 수 차이를 고려한 통계적 검정 및 시계열 비교 분석
분석 결과의 통계적 신뢰성 강화

THANK YOU

감사합니다

GITHUB REPO

github.com/miracleharuforall/fun1-20260524

STREAMLIT DEMO

fun1-20260524.streamlit.app