

국내 금융회사 개인정보처리방침 준수 여부 자동 검토

개인정보처리방침 PDF OCR·자동평가·EDA·Streamlit·RAG 확장 프로토타입

항목	내용
분석 대상	국내 금융회사 개인정보처리방침 (122 개사)
분석 기준	개인정보보호위원회 「개인정보 처리방침 작성지침(26 년 4 월 기준)」 기반 24 개 체크리스트
분석 방법	PDF OCR, 텍스트 정제, threshold 기반 자동평가, EDA, Streamlit 시각화
확장 기능	JSON 구조화, ChromaDB, VectorDB, OpenAI API 기반 RAG 질의응답 프로토타입
GitHub	https://github.com/miracleharuforall/fun1-20260524
Streamlit	https://fun1-20260524.streamlit.app

목차

1. 프로젝트 개요
2. 데이터 수집 결과
3. 데이터 전처리
4. 자동평가 방법
5. 탐색적 데이터 분석(EDA)
6. 주요 인사이트
7. Streamlit 대시보드 구현
8. RAG 질의응답 프로토타입
9. AWS 인프라 구성 및 확장 설계
10. LDA 이론 소개
11. 한계 및 향후 개선방안

1. 프로젝트 개요

1.1 프로젝트 주제

본 프로젝트는 국내 금융회사 홈페이지에 공개된 개인정보처리방침 PDF 를 수집하고, 개인정보보호위원회 「개인정보 처리방침 작성지침(‘26 년 4 월 기준)」의 주요 기재사항을 기준으로 자동 평가 및 탐색적 데이터 분석(EDA)을 수행한 데이터마이닝 프로젝트이다. 분석 결과는 Streamlit 대시보드로 시각화 하였으며, 추가 확장으로 JSON 구조화, ChromaDB, VectorDB, OpenAI API 기반 RAG 질의응답 프로토타입까지 구성하였다.

1.2 선정 이유

금융회사는 민감하고 중요한 개인정보를 대규모로 처리한다. 개인정보처리방침은 정보주체가 자신의 개인정보가 어떻게 수집·이용·제공·보관·파기되는지 확인할 수 있는 공개문서이다.

본 프로젝트는 특히 중소형 금융회사나 인력이 제한된 조직에서는 보안, 개인정보보호, 전산, 준법 관련 업무를 소수 인력이 겸직하는 경우가 많다. 이 경우 개인정보처리방침의 주요 기재사항을 효율적으로 점검할 수 있는 방법을 모색하기 위해 선정하였다. 개인정보처리방침은 공개 문서이고 문서 구조가 비교적 정형화되어 있어 OCR, 텍스트 정제, 키워드 기반 자동평가를 적용하면 정형화된 항목에 대해서는 반복 가능한 자동 점검이 가능할 것으로 판단하였다.

또한 분석 결과는 개인정보처리방침 개선, 내부 점검, 교육 자료 작성 등에 활용 가능하며, 향후 JSON 구조화, VectorDB, LLM 을 연계하면 자연어 기반 RAG 점검 서비스로도 확장할 수 있다. 이러한 점에서 본 프로젝트는 데이터마이닝 기법을 실제 금융 IT·개인정보보호 업무에 연결할 수 있는 실용적 주제라고 판단하였다.

1.3 연구 질문

1. 국내 금융회사의 개인정보처리방침은 작성지침의 주요 기재사항을 얼마나 충족하고 있는가?
2. 금융회사 업권별로 개인정보처리방침 기재 수준에 차이가 있는가?
3. 어떤 작성지침 항목이 가장 자주 누락되거나 낮게 기재되는가?
4. 국외이전, 가명정보, 자동수집장치, 제 3 자 행태정보, 자동화된 결정 등 디지털·신기술 관련 항목의 공개 수준은 업권별로 어떤 차이를 보이는가?
5. 정제된 개인정보처리방침 데이터를 JSON 과 VectorDB 로 확장하면 자연어 기반 질의응답에 활용할 수 있는가?

1.4 프로젝트 전체 처리 흐름

PDF 수집

- OCR 텍스트 추출
- OCR 노이즈 제거
- clean_text_v3 생성
- 1,000 자 미만 문서 제외
- 24 개 체크리스트 기반 자동평가
- 업권 정보 및 URL 병합
- EDA 분석
- Streamlit 대시보드 시각화
- JSON 구조화
- chunk 분할
- VectorDB 구축
- RAG 기반 자연어 질의응답 프로토타입

그림 1. 전체 처리 흐름

전체 분석 파이프라인

금융회사 개인정보처리방침 PDF를 수집한 뒤 OCR, 텍스트 정제, 자동평가, EDA, Streamlit 시각화까지 수행한 기본 처리 흐름입니다.



※ 본 프로젝트의 기본 분석은 공개 개인정보처리방침의 명시 여부를 기준으로 하며, 조건부 항목은 법 위반 여부가 아닌 공개 수준으로 해석합니다.

RAG 확장 파이프라인

정제된 개인정보처리방침 텍스트를 JSON과 chunk로 구조화한 뒤, VectorDB와 OpenAI API를 활용해 자연어 질의응답 프로토타입으로 확장했습니다.



※ RAG 기능은 로컬 환경에서 실행 가능한 프로토타입으로 구현했으며, Streamlit Cloud 배포본은 기본 분석 대시보드 중심으로 제공합니다.

2. 데이터 수집 결과

2.1 수집 대상

분석 대상은 국내 금융회사 홈페이지에 공개된 개인정보처리방침이다. 최초 수집한 PDF 는 130 개였으며, OCR 정제 후 텍스트 길이가 1,000 자 미만인 파일을 제외하여 최종 122 개 금융회사 문서를 분석 대상으로 확정하였다. 본 보고서와 Streamlit 대시보드의 모든 분석 결과는 최종 122 개 표본을 기준으로 작성하였다.

구분	수량	설명
최초 PDF 수집	130 개	금융회사 홈페이지에서 Print > PDF 방식으로 저장
OCR 및 텍스트 정제	130 개	Tesseract OCR 및 정규표현식 기반 정제 수행
제외 문서	8 개	OCR 정제 후 텍스트 1,000 자 미만 문서 제외
최종 분석 대상	122 개	업권 분류 및 자동평가 대상 확정

그림 2. raw_pdf 폴더 및 PDF 개수 확인

수집한 개인정보처리방침 PDF 파일은 data/raw_pdf 폴더에 저장하였으며, PowerShell 명령어를 통해 최종 분석 대상 PDF 개수를 확인하였다.

```

PS C:\privacy-policy-mining> Write-Host "raw_pdf 폴더 PDF 개수:"
raw_pdf 폴더 PDF 개수:
PS C:\privacy-policy-mining> (Get-ChildItem -Path data\raw_pdf -Filter *.pdf).Count
122
PS C:\privacy-policy-mining>
PS C:\privacy-policy-mining> Write-Host "`nPDF 파일 샘플:"
PDF 파일 샘플:
PS C:\privacy-policy-mining> Get-ChildItem -Path data\raw_pdf -Filter *.pdf | Select-Object -First 10 Name
Name
----
AIA생명보험.pdf
AIG손해보험.pdf
BNK부산은행.pdf
BNK캐피탈.pdf
BNP파리바카디프생명보험.pdf
DB손해보험.pdf
IBK기업은행.pdf
IBK연금보험.pdf
IBK캐피탈.pdf
JB우리캐피탈.pdf

```

2.2 업권 분류

최종 분석 대상 122 개 금융회사는 은행, 금융투자, 보험, 금융유관기관, 중소서민, 가상자산사업자, 전자금융업자, 핀테크, 보험 GA 로 분류하였다. 업권 분류는 업권별 평균 준수율, 필수항목 준수율, 디지털 투명성 지표, 정보주체 권리보장 지표를 비교하기 위한 기준 변수로 사용하였다.

업권	분류 기준
은행	1. 「은행법」에 따른 은행 2. 「한국산업은행법」에 따른 한국산업은행 3. 「중소기업은행법」에 따른 중소기업은행 4. 「농업협동조합법」에 따른 농협은행 5. 「수산업협동조합법」에 따른 수산업 협동조합중앙회의 신용사업부문
금융투자	1. 「자본시장과금융투자업에관한법률」에 따른 금융투자업자 및 종합금융회사
보험	1. 「보험업법」에 따른 보험회사
금융유관기관	1. 사단법인 금융결제원 2. 「자본시장과 금융투자업에 관한법률」에 따른 한국예탁결제원, 한국거래소, 증권금융회사 및 다자간매매체결회사 3. 주식회사 코스콤 4. 「신용정보의 이용 및 보호에 관한 법률」에 따른 종합 신용정보 집중기관
중소서민	1. 「여신전문금융업법」에 따른 여신전문 금융회사 2. 「새마을금고법」에 따른 새마을금고중앙회 3. 「농업협동조합법」에 따른 농업협동조합중앙회 4. 「상호저축은행법」에 따른 상호저축은행중앙회 5. 「신용협동조합법」에 따른 신용협동조합중앙회 6. 「산림조합법」에 따른 산림조합중앙회의신용사업부문 7. 「신용정보의 이용 및 보호에 관한 법률」에 따른 신용정보회사
가상자산사업자	1. 「가상자산 이용자 보호 등에 관한 법률」 및 「특정금융정보의보고 및 이용 등에 관한 법률」에 따른 가상자산사업자
전자금융업자	1. 「전자금융거래법」에 따른 전자금융업자
핀테크	금융 플랫폼, 마이데이터, 간편 금융서비스 등 기술 기반 금융서비스를 제공하는 회사
보험 GA	보험상품의 판매·모집 업무를 수행하는 법인보험대리점 또는 보험대리점 관련 업권

2.3 개인정보처리방침 URL 관리

데이터 출처의 재현성을 높이기 위해 금융회사별 개인정보처리방침 URL 을 별도 엑셀 파일로 관리하였다. URL 마스터 파일(185 개사)을 기준*으로 최종 분석 대상 122 개 회사에 해당하는 URL 을 companies.csv 에 병합해서, Streamlit 대시보드에서 회사별 개인정보처리방침 URL 까지 확인 가능하게 했다.

* 마스터 파일 URL 기준 Print> PDF 방식으로 저장 불가한 55 개사와 OCR 정제 후 텍스트 1,000 자 미만인 8 개사는 분석 대상에서 제외

파일명	역할
policy_url_master_185.xlsx	금융회사별 개인정보처리방침 URL 마스터
policy_url_merge_check.xlsx	URL 병합 검토 파일
companies.csv	최종 분석 대상 122 개 회사의 업권, 파일명, URL 정보

그림 3. 회사별 상세 조회 화면의 개인정보처리방침 URL 표시

URL 마스터 파일과 최종 분석 대상 회사 목록을 병합한 결과, Streamlit 의 회사별 상세 조회 화면에서 각 금융회사의 업권, PDF 파일명, 개인정보처리방침 원문 URL 을 함께 확인할 수 있도록 구성하였다.

회사별 상세 조회

특정 회사를 선택하여 24개 체크리스트 항목별 자동평가 결과와 매칭된 키워드, 그리고 실제 개인정보처리방침 수집 URL을 확인합니다.

회사 선택 목록은 총 122개입니다. Streamlit 선택창은 전체 회사를 한 번에 모두 펼쳐 보여주지 않고 일부만 표시합니다. 드롭다운에서 스크롤하거나 회사명을 직접 입력해서 검색할 수 있습니다.

> 전체 회사 목록 보기

회사 선택

AIA생명보험

수집 출처 정보

업권

보험

URL 상태

checked

PDF 파일

AIA생명보험.pdf

개인정보처리방침 URL: <https://www.aia.co.kr/ko/footer/customer-right-information/privacyty-policy-guide/pi-processing/20260501.html>

회사 평가 요약

company_name	C01	C02	C03	C04	C05	C06	C07	C08	C09	C10	C11	C12	C13	C14	C15	C16	C17	C18	C19	C20
AIA생명보험	1	1	1	1	1	1	1	0	1	1	0	0	1	1	0	1	0	1	0	1

2.4 데이터 수집 코드

PDF 파일명에서 회사 목록을 생성하고, OCR 처리 및 정제 결과와 병합하기 위해 src 폴더에 수집·전처리 코드를 분리하였다. 주요 수집 및 전처리 코드는 extract_pdf_ocr.py, clean_ocr_text_v3.py, make_companies_from_pdf.py, merge_policy_urls_from_master.py 이다.

그림 4. src 폴더의 수집 및 전처리 코드 목록

```
> src
├── __init__.py
├── build_vectordb.py
├── clean_ocr_text_v3.py
├── convert_to_json.py
├── eda_analysis.py
├── evaluation_engine_v3.py
├── extract_pdf_ocr.py
├── extract_pdf_text.py
├── extract_required_results.py
├── make_analysis_dataset.py
├── make_checklist_v2.py
├── make_chunks.py
├── make_companies_from_pdf.py
├── merge_policy_urls_from_master.py
├── rag_answer.py
├── rag_engine.py
└── search_vectordb.py
```

PDF 파일에서 회사 목록을 생성하고, OCR 처리 및 정제 결과와 병합하기 위해 수집·전처리 코드를 src 폴더에 분리하여 관리하였다.

주요 수집 및 전처리 코드는 extract_pdf_ocr.py, clean_ocr_text_v3.py, make_companies_from_pdf.py, merge_policy_urls_from_master.py 이다.

3. 데이터 전처리

3.1 PDF OCR 추출

PDF 문서는 Tesseract OCR 과 Poppler 를 활용해 텍스트로 변환하였다. PDF 파일은 금융회사별로 형태와 품질이 다르므로, 일반 PDF 텍스트 추출 방식만으로는 모든 문서를 안정적으로 처리하기 어렵다. 따라서 OCR 기반 추출 방식을 사용하여 스캔형 또는 이미지 기반 PDF 에서도 텍스트를 확보할 수 있도록 하였다.

그림 5. Tesseract 버전 및 Poppler 경로 확인

PDF 문서의 OCR 처리를 위해 Tesseract OCR 과 Poppler 설치 상태를 확인하였다. 또한 한국어 문서 처리를 위해 kor.traineddata 파일이 정상적으로 존재하는지 확인하였다.

```
PS C:\privacy-policy-mining> & "C:\Program Files\Tesseract-OCR\tesseract.exe" --version
libgif 5.2.2 : libjpeg 8d (libjpeg-turbo 3.0.4) : libpng 1.6.44 : libtiff 4.7.0 : zlib 1.3.1 : libwebp 1.4.0 : libopenjp2 2.5.2
Found AVX512BW
Found AVX512F
Found AVX512VNNI
Found AVX2
Found AVX
Found FMA
Found SSE4.1
Found libarchive 3.7.7 zlib/1.3.1 liblzma/5.6.3 bz2lib/1.0.8 liblz4/1.10.0 libzstd/1.5.6
Found libcurl/8.11.0 Schannel zlib/1.3.1 brotli/1.1.0 zstd/1.5.6 libidn2/2.3.7 libpsl/0.21.5 libssh2/1.11.0
```



```
PS C:\privacy-policy-mining> Get-ChildItem C:\ -Directory | Where-Object { $_.Name -like "*poppler*" }

디렉터리: C:\

Mode                LastWriteTime         Length Name
----                -
d-----         2026-05-17 오후 6:26             poppler
```

그림 6. extract_pdf_ocr.py 실행

extract_pdf_ocr.py 를 실행하여 data/raw_pdf 폴더의 개인정보처리방침 PDF 문서를 OCR 로 변환하였고, 추출 결과를 processed_policies_ocr.csv 파일로 저장하였다.

[1/122] OCR 처리 중... 출력 화면

```
PS C:\privacy-policy-mining> python src/extract_pdf_ocr.py
[1/122] OCR 처리 중: AIA생명보험.pdf
[2/122] OCR 처리 중: AIG손해보험.pdf
[3/122] OCR 처리 중: BNK부산은행.pdf
[4/122] OCR 처리 중: BNK캐피탈.pdf
[5/122] OCR 처리 중: BNP파리바카디프생명보험.pdf
[6/122] OCR 처리 중: DB손해보험.pdf
[7/122] OCR 처리 중: IBK기업은행.pdf
[8/122] OCR 처리 중: IBK연금보험.pdf
[9/122] OCR 처리 중: IBK캐피탈.pdf
[10/122] OCR 처리 중: JB우리캐피탈.pdf
```

[122/122] OCR 완료 출력 화면

```
[115/122] OCR 처리 중: 해빗팩토리.pdf
[116/122] OCR 처리 중: 헥토이노베이션.pdf
[117/122] OCR 처리 중: 현대카드.pdf
[118/122] OCR 처리 중: 현대캐피탈.pdf
[119/122] OCR 처리 중: 현대커머셜.pdf
[120/122] OCR 처리 중: 현대해상화재보험.pdf
[121/122] OCR 처리 중: 흥국생명보험.pdf
[122/122] OCR 처리 중: 흥국화재해상보험.pdf
```

```
PS C:\privacy-policy-mining> python -c "import pandas as pd; df=pd.read_csv('data/processed_policies_ocr.csv'); print(df[['file_name','company_name','text_length','extract_status']].head()); print(df['extract_status'].value_counts())"
file_name company_name text_length extract_status
0 AIA생명보험.pdf AIA생명보험 23859 success
1 AIG손해보험.pdf AIG손해보험 21401 success
2 BNK부산은행.pdf BNK부산은행 18178 success
3 BNK캐피탈.pdf BNK캐피탈 11966 success
4 BNP파리바카디프생명보험.pdf BNP파리바카디프생명보험 10369 success
extract_status
success 122
Name: count, dtype: int64
```

3.2 OCR 노이즈 제거

OCR 결과에는 웹사이트 메뉴, 페이지 이동 문구, 특수문자, URL, 반복 공백, 깨진 문자열 등이 포함될 수 있다.

clean_ocr_text_v3.py에서는 정규표현식 기반으로 불필요한 문구를 제거하고, 분석에 필요한 본문 중심의 clean_text_v3를 생성하였다.

통계 항목	값
정제 대상 PDF 수	122 개
평균 정제 텍스트 길이	약 10,837 자
최소 정제 텍스트 길이	3,060 자
최대 정제 텍스트 길이	31,987 자

그림 7. clean_ocr_text_v3.py 실행 결과 및 clean_length_v3 통계 화면

clean_ocr_text_v3.py를 실행하여 OCR 결과에 포함된 웹사이트 메뉴, URL, 특수문자, 반복 공백 등 불필요한 노이즈를 제거하였다. 정제 결과 최종 분석 대상은 122 개 문서이며, 평균 정제 텍스트 길이는 약 10,837 자, 최소 길이는 3,060 자, 최대 길이는 31,987 자로 확인되었다.

```

PS C:\privacy-policy-mining> python src/clean_ocr_text_v3.py
정제 대상 PDF 수: 122
C:\privacy-policy-mining\src\clean_ocr_text_v3.py:158: UserWarning: Cell contents too long (36069), truncated to 32767 characters
  df.to_excel(
C:\privacy-policy-mining\src\clean_ocr_text_v3.py:158: UserWarning: Cell contents too long (33898), truncated to 32767 characters
  df.to_excel(
C:\privacy-policy-mining\src\clean_ocr_text_v3.py:158: UserWarning: Cell contents too long (33662), truncated to 32767 characters
  df.to_excel(
C:\privacy-policy-mining\src\clean_ocr_text_v3.py:158: UserWarning: Cell contents too long (46995), truncated to 32767 characters
  df.to_excel(
C:\privacy-policy-mining\src\clean_ocr_text_v3.py:158: UserWarning: Cell contents too long (43855), truncated to 32767 characters
  df.to_excel(
정제 완료
CSV 저장: C:\privacy-policy-mining\data\processed_policies_cleaned_v3.csv
XLSX 저장: C:\privacy-policy-mining\data\processed_policies_cleaned_v3.xlsx
count      122.000000
mean      10837.065574
std        5229.882038
min        3060.000000
25%        6998.750000
50%        9881.000000
75%       13572.000000
max       31987.000000
Name: clean_length_v3, dtype: float64

```

3.3 결측치 및 이상치 처리

본 프로젝트에서 가장 중요한 품질 기준은 OCR 정제 후 텍스트 길이였다. 정제 후 텍스트가 1,000 자 미만인 문서는 개인정보처리방침 본문이 충분히 추출되지 않았거나 분석 신뢰도가 낮다고 판단하여 제외하였다. 이 과정을 통해 최초 130 개 문서에서 최종 122 개 문서로 분석 표본을 확정하였다.

처리 항목	처리 방식	이유
텍스트 길이 1,000 자 미만	분석 대상에서 제외	본문 추출 부족으로 자동평가 신뢰도 저하 가능
URL 결측	URL 마스터와 병합하여 보완	출처 재현성 확보
OCR 노이즈	정규표현식 기반 제거	평가 키워드 매칭 정확도 개선
조건부 항목 미기재	법 위반으로 단정하지 않음	실제 해당 처리 여부 확인 필요

3.4 PDF 텍스트의 JSON 구조화

기본 분석은 CSV/XLSX 기반으로 수행하였으나, RAG 질의응답 확장을 위해 정제 텍스트를 회사별 JSON 으로 구조화하였다. JSON 에는 회사명, 업권, PDF 파일명, 개인정보처리방침 URL, 정제 텍스트, 체크리스트 평가 결과, 매칭 키워드, 텍스트 길이 등의 메타데이터를 포함하도록 설계하였다.

```
{
  "company_name": "AIA 생명보험",
  "sector": "보험",
  "file_name": "AIA 생명보험.pdf",
  "policy_url": "https://...",
  "clean_text": "개인정보처리방침 본문...",
  "checklist_results": [
    {
      "item_id": "C01",
      "item_name": "제목 및 서문",
      "requirement_type": "required",
      "score": 1,
      "matched_keywords": "개인정보처리방침"
    }
  ],
  "metadata": {
    "text_length": 23859
  }
}
```

4. 자동평가 방법

4.1 24 개 체크리스트 구성

개인정보 처리방침 작성지침을 기준으로 24 개 체크리스트 항목을 구성하였다. 각 항목은 item_id, item_name, requirement_type, 평가 키워드, 최소 매칭 수로 구성되며, 개인정보처리방침 텍스트에서 관련 키워드가 일정 기준 이상 발견되면 해당 항목을 충족한 것으로 판정하였다.

컬럼	설명
item_id	체크리스트 항목 ID(C01~C24)
item_name	체크리스트 항목명
requirement_type	required, conditional, recommended, conditional_recommended
regex_keywords	자동평가에 사용하는 키워드 또는 정규표현식
min_match_count	충족 판정을 위한 최소 매칭 수

그림 8. checklist.csv 생성 결과

make_checklist_v2.py 를 실행하여 개인정보 처리방침 작성지침 기반의 24 개 체크리스트 항목을 생성하였다. 각 항목은 item_id, item_name, requirement_type, regex_keywords, min_match_count 로 구성되며, 자동평가 시 개인정보처리방침 텍스트에서 관련 키워드가 최소 매칭 수 이상 발견되면 해당 항목을 충족한 것으로 판정하였다.

```

PS C:\privacy-policy-mining> python src/make_checklist_v2.py
checklist.csv 생성 완료: C:\privacy-policy-mining\data\checklist.csv
  item_id      item_name      min_match_count
0      C01      제목 및 서문      1
1      C02      개인정보의 처리 목적      1
2      C03      처리하는 개인정보의 항목      2
3      C04      14세 미만 아동의 개인정보 처리      2
4      C05      개인정보의 처리 및 보유 기간      2
5      C06      개인정보의 파기 절차 및 방법      2
6      C07      개인정보의 제3자 제공      3
7      C08      추가적인 이용·제공 판단 기준      3
8      C09      개인정보 처리업무의 위탁      2
9      C10      개인정보의 국외 수집 및 이전      3
10     C11      개인정보의 안전성 확보조치      3
11     C12      민감정보의 공개 가능성 및 비공개 선택 방법      2
12     C13      가명정보 처리      2
13     C14      개인정보 자동 수집 장치 설치·운영 및 거부      2
14     C15      제3자 행태정보 수집 허용·거부      3
15     C16      정보주체와 법정대리인의 권리·의무 및 행사방법      3
16     C17      자동화된 결정      2
17     C18      개인정보 보호책임자 및 담당부서      2
18     C19      국내대리인 지정      2
19     C20      정보주체의 권익침해 구제방법      2
20     C21      고정형 영상정보처리기기 운영·관리      3
21     C22      이동형 영상정보처리기기 운영·관리      3
22     C23      자율적 개인정보 보호활동      1
23     C24      개인정보 처리방침의 변경      2

```

4.2 requirement_type 구분

유형	의미	해석상 주의
required	필수 성격의 기본 기재사항	기본 고지사항의 충족 수준을 직접적으로 해석 가능
conditional	해당 개인정보 처리를 수행하는 경우 기재하는 항목	미기재를 곧바로 법 위반으로 해석하지 않음
recommended	투명성 강화를 위한 권장항목	문서 품질과 투명성 수준을 보조적으로 해석
conditional_recommended	해당시 권장항목	실제 해당 여부 확인 필요

4.3 threshold 기반 자동평가 방식

자동평가는 각 항목별 평가 키워드가 정제 텍스트에서 몇 개 발견되는지를 계산하고, matched_count 가 min_match_count 이상이면 score=1, 그렇지 않으면 score=0 으로 판정하는 방식이다. 이 방식은 대규모 문서의 반복 평가에는 효율적이지만, 문맥적 의미를 완전히 반영하지 못할 수 있으므로 해석 시 주의가 필요하다.

```

if matched_count >= min_match_count:
    score = 1
else:
    score = 0
  
```

✓ 추가 계산식:

- 회사별 전체 준수율 = 충족 항목 수 / 전체 체크리스트 항목 수 × 100,
- 업권별 평균 준수율 = 동일 업권 회사들의 회사별 준수율 평균,
- 업권별 필수항목 준수율 = required 항목 중 충족 항목 수 / required 항목 전체 수 × 100,
- 항목별 누락률 = 해당 항목 미충족 회사 수 / 전체 회사 수 × 100 으로 산정

그림 9. evaluation_engine_v3.py 실행 완료 화면

```

PS C:\privacy-policy-mining> python src/evaluation_engine_v3.py
threshold 기반 24개 체크리스트 자동평가 완료
엑셀 저장: C:\privacy-policy-mining\data\evaluation_result_24_threshold.xlsx
CSV 저장: C:\privacy-policy-mining\data\evaluation_result_24_threshold.csv
  company_name  total_score  total_items  compliance_rate
0      ATIA생명보험           16           24           66.7
1      AIG손해보험           16           24           66.7
2      BNK부산은행           16           24           66.7
3      BNK캐피탈           13           24           54.2
4  BNP파리바카디프생명보험           11           24           45.8

회사 수: 122
PS C:\privacy-policy-mining> dir data\evaluation_result_24_threshold*

디렉터리: C:\privacy-policy-mining\data

Mode                LastWriteTime         Length Name
----                -
-a----          2026-05-25 오전 1:07             9624 evaluation_result_24_threshold.csv
-a----          2026-05-25 오전 1:07          147083 evaluation_result_24_threshold.xlsx

```

5. 탐색적 데이터 분석(EDA)

5.1 분석 지표

EDA에서는 전체 평균 준수율, 필수항목 준수율, requirement_type 별 충족률, 체크리스트 항목별 누락률, 업권별 종합 비교, 업권 × 체크리스트 항목 히트맵, 디지털 개인정보 처리 투명성 지표, 정보주체 권리보장 지표를 분석하였다.

지표	설명
전체 평균 준수율	24 개 전체 항목 기준 평균 기재율
필수항목 준수율	required 항목만 대상으로 산정한 준수율
항목별 누락률	각 체크리스트 항목이 미충족으로 판정된 비율
디지털 개인정보 처리 투명성 지표	C10, C13, C14, C15, C17 기반 파생지표
정보주체 권리보장 지표	C14, C16, C17, C18, C20, C24 기반 파생지표

5.2 주요 결과

항목	결과
최종 분석 대상	122 개
체크리스트 항목	24 개

전체 평균 준수율	54.5%
필수항목 충족률	82.0%
conditional 항목 충족률	38.1%
recommended 항목 충족률	54.9%
conditional_recommended 항목 충족률	4.1%

그림 10. Streamlit 핵심 지표 화면

Streamlit 핵심 지표 화면에서는 최종 분석 대상 122 개 회사, 체크리스트 24 개 항목, 전체 평균 준수율 54.5%, 필수항목 충족률 82.0% 등을 요약하여 확인할 수 있다. 또한 requirement_type 별 충족률을 함께 제시하여 필수항목과 해당 시·권장 항목 간 기재 수준 차이를 비교할 수 있도록 구성하였다.

핵심 지표

최종 분석 대상

122개

체크리스트 항목

24개

전체 평균 준수율

54.5%


필수항목 충족률

82.0%

기재 유형별 핵심 수치

구분	충족률	해석
required	82	필수 성격의 기본 기재사항
conditional	38.1	해당 개인정보 처리가 있는 경우 기재
recommended	54.9	투명성 강화를 위한 권장 항목

기재 유형별 충족률 요약



5.3 업권별 종합 비교

업권별 종합 비교에서는 전체 평균 준수율, 필수항목 준수율, 디지털 투명성 지표, 정보주체 권리보장 지표를 함께 비교하였다. 대부분 업권에서 필수항목 준수율은 전체 평균 준수율보다 높게 나타났다. 이는 기본적인 필수 기재사항은 비교적 안정적으로 반영되어 있으나, 해당 시·권장 항목까지 포함하면 전체 기재 수준이 낮아진다는 점을 보여준다.


그림 11. 업권별 종합 비교 그래프

업권별 종합 비교 그래프에서는 전체 평균 준수율, 필수항목 준수율, 디지털 개인정보 처리 투명성 지표, 정보주체 권리보장 지표를 함께 비교하였다. 대부분 업권에서 필수항목 준수율은 전체 평균 준수율보다 높게 나타났으며, 이는 기본적인 필수 기재사항은 비교적 안정적으로 반영되어 있으나 해당 시·권장 항목까지 포함하면 전체 기재 수준이 낮아진다는 점을 보여준다.

1. 업권별 종합 비교

전체 평균 준수율, 필수항목 준수율, 디지털 개인정보 처리 투명성 지표, 정보주체 권리보장 지표를 하나의 그래프에서 비교합니다.

업권별 주요 지표 비교



sector	company_count	avg_compliance_rate	required_compliance_rate	digital_transparency_score	rights_protection_score
은행	13	67.9	88	60	80.8
가상자산사업자	3	58.3	88.9	46.7	77.8
금융투자	17	57.8	88.2	32.9	72.5
금융유관기관	4	57.3	88.9	30	79.2
핀테크	7	54.2	85.7	34.3	71.4
중소서민	36	53	80.2	31.1	64.4
보험	23	52.4	77.8	34.8	70.3
보험GA	7	51.8	84.1	14.3	66.7
전자금융업자	12	44.1	72.2	26.7	56.9

5.4 업권별 필수항목 준수율

required 항목만 대상으로 한 필수항목 준수율은 전체 24 개 기준 평균보다 높게 나타났다. 이는 개인정보 처리 목적, 처리 항목, 보유기간, 파기, 보호책임자, 정보주체 권리 등 기본 고지사항은 상대적으로 잘 기재되고 있음을 의미한다.


그림 12. 업권별 필수항목 준수율 그래프

업권별 필수항목 준수율은 개인정보처리방침 작성지침 중 required 항목만을 대상으로 산정하였다. 분석 결과 대부분의 업권에서 필수항목 준수율은 전체 24 개 항목 기준 평균 준수율보다 높게 나타났다. 이는 금융회사들이 개인정보 처리 목적, 처리 항목, 보유기간, 파기, 보호책임자, 정보주체 권리 등 기본적인 필수 기재사항은 비교적 충실히 반영하고 있음을 보여준다. 다만 이 지표는 필수항목만을 대상으로 하므로, 해당시·권장 항목까지 포함한 개인정보처리방침의 전체 기재 수준과는 구분하여 해석할 필요가 있다.

2. 업권별 필수항목 준수율

required 항목만 대상으로 산정한 준수율입니다. 전체 24개 기준 준수율보다 법정 필수 성격의 기본 기재 수준을 더 정확히 보여줍니다.

업권별 필수항목 준수율



sector	required_pass_count	required_total_count	company_count	required_compliance_rate
가상자산사업자	24	27	3	88.9
금융유관기관	32	36	4	88.9
금융투자	135	153	17	88.2
은행	103	117	13	88
핀테크	54	63	7	85.7
보험GA	53	63	7	84.1
중소서민	260	324	36	80.2
보험	161	207	23	77.8
전자금융업자	78	108	12	72.2

5.5 requirement_type 별 충족률

required 항목 충족률은 82.0%로 가장 높았고, conditional 항목은 38.1%로 낮게 나타났다. 다만 conditional 항목은 모든 회사에 일률적으로 적용되는 항목이 아니므로, 낮은 충족률을 법 위반율로 해석하지 않고 공개된 처리방침상 명시 수준으로 해석하였다.


그림 13. requirement_type 별 충족률 그래프

requirement_type 별 충족률 분석은 개인정보처리방침 체크리스트 항목을 기재 성격에 따라 구분하여 충족 수준을 비교한 것이다. required 항목은 모든 금융회사에 공통적으로 요구되는 기본 기재사항이므로 가장 높은 충족률을 보였고, conditional 항목은 실제 해당 개인정보 처리를 수행하는 경우에 기재하는 항목이므로 상대적으로 낮게 나타났다. 따라서 conditional 항목의 낮은 충족률은 곧바로 법 위반율로 해석하기보다, 공개된 개인정보처리방침상 명시 여부가 낮은 항목으로 해석하는 것이 타당하다.


3. requirement_type별 충족률

필수항목과 해당시·권장 항목 사이의 충족률 차이를 확인합니다.

기재 유형별 충족률



충족 항목 구성



requirement_type	pass_count	total_count	pass_rate	missing_rate
conditional	558	1464	38.1	61.9
conditional_recommended	5	122	4.1	95.9
recommended	134	244	54.9	45.1
required	900	1098	82	18

5.6 체크리스트 항목별 누락률

항목별 누락률 분석에서는 국내대리인, 제 3 자 행태정보, 영상정보처리기기, 자동화된 결정 등 조건부 항목에서 높은 누락률이 나타났다. 이는 실제 미준수라기보다 해당 처리 여부가 있는 경우에만 기재되는 항목의 특성이 반영된 결과로 해석해야 한다.


구체적으로 누락률이 가장 높은 항목은 C19 국내대리인 지정(100.0%)이었고, C15 제 3 자 행태정보 수집 허용·거부(95.9%), C22 이동형 영상정보처리기기 운영·관리(95.1%)도 높은 누락률을 보였다. 다만 이들 항목은 대부분 조건부 항목이므로, 누락률을 곧바로 법 위반율로 해석하지 않았다.

그림 14. 체크리스트 항목별 누락률 그래프

체크리스트 항목별 누락률 분석은 24 개 평가 항목 중 공개된 개인정보처리방침에서 상대적으로 명시 수준이 낮은 항목을 확인하기 위한 것이다. 누락률 상위 항목에는 국내대리인 지정, 제 3 자 행태정보 수집 허용·거부, 영상정보처리기기 운영·관리, 자동화된 결정 등 조건부 항목이 다수 포함되었다. 이러한 항목은 실제 해당 개인정보 처리를 수행하는 경우에 기재하는 항목이므로, 높은 누락률을 곧바로 미준수나 법 위반으로 단정할 수 없다. 본 연구에서는 이를 공개된 개인정보처리방침상 명시 여부가 낮은 항목으로 해석하였다.

4. 체크리스트 항목별 누락률

어떤 항목이 가장 자주 미기재 또는 미충족으로 판정되었는지 확인합니다. 색상은 requirement_type을 의미합니다.



주의

누락률 상위 항목은 대부분 해당시 항목입니다. 해당시 항목은 실제 해당 개인정보 처리를 수행하는 경우에 기재하는 항목이므로, 낮은 기재율을 곧바로 법 위반으로 해석하지 않습니다.

item_id	item_name	requirement_type	pass_rate	missing_rate
C19	국내대리인 지정	conditional	0	100
C15	제3자 행태정보 수집 허용·거부	conditional_recommended	4.1	95.9
C22	이동형 영상정보처리기기 운영·관리	conditional	4.9	95.1
C12	민감정보의 공개 가능성 및 비공개 선택 방법	conditional	9.8	90.2
C17	자동화된 결정	conditional	16.4	83.6

5.7 업권 × 체크리스트 항목 히트맵

업권 × 체크리스트 항목 히트맵은 업권별로 어떤 항목의 충족률이 높거나 낮은 지 한눈에 확인하기 위한 시각화이다. 색이 진할수록 해당 업권에서 해당 항목의 기재율이 높은 것이고, 색이 옅을수록 기재율이 낮다는 의미이다.


그림 15. 업권 × 체크리스트 항목 히트맵

업권 × 체크리스트 항목 히트맵은 금융회사 업권별 개인정보처리방침 기재 수준의 차이를 세부 항목 단위로 비교하기 위한 시각화이다. 분석 결과 기본 필수항목은 대부분 업권에서 상대적으로 높은 충족률을 보였으나, 국외이전, 제 3 자 행태정보, 자동화된 결정, 영상정보처리기기 등 조건부·디지털 관련 항목은 업권별 편차가 크게 나타났다. 이는 개인정보처리방침의 기본 기재사항은 비교적 안정적으로 반영되어 있으나, 디지털 환경 또는 특정 개인정보 처리 활동과 관련된 항목은 업권별로 명시 수준이 다를 수 있음을 보여준다.

5. 업권 × 체크리스트 항목 히트맵

행은 업권, 열은 체크리스트 항목이며, 각 셀의 숫자는 해당 업권에서 해당 항목을 충족한 비율입니다.

업권 × 체크리스트 항목 충족 히트맵



5.8 디지털 투명성 vs 정보주체 권리보장

디지털 개인정보 처리 투명성 지표는 국외이전, 가명정보, 자동수집장치, 제 3 자 행태정보, 자동화된 결정 등 디지털 환경의 개인정보 처리 공개 수준을 비교하기 위해 구성한 파생지표이다. 정보주체 권리보장 지표는 권리행사, 자동수집장치 거부, 자동화된 결정 관련 권리, 보호책임자, 권익침해 구제, 처리방침 변경 항목을 묶어 구성하였다. 분석 결과 대부분 업권에서 정보주체 권리보장 지표가 디지털 투명성 지표보다 높게 나타났다.


그림 16. 디지털 투명성 vs 정보주체 권리보장 버블차트

디지털 투명성 vs 정보주체 권리보장 버블차트는 본 프로젝트에서 구성한 두 개의 파생지표를 활용하여 업권별 개인정보처리방침의 기재 특성을 비교한 것이다. 디지털 개인정보 처리 투명성 지표는 국외이전, 가명정보, 자동수집장치, 제 3 자 행태정보, 자동화된 결정 등 디지털 환경의 개인정보 처리 공개 수준을 비교하기 위해 구성하였다. 정보주체 권리보장 지표는 권리행사, 자동수집장치 거부, 자동화된 결정 관련 권리, 보호책임자, 권익침해 구제, 처리방침 변경 항목을 묶어 구성하였다. 분석 결과 대부분의 업권에서 정보주체 권리보장 지표가 디지털 투명성 지표보다 높게 나타났으며, 이는 기본적인 권리보장 안내는 상대적으로 잘 기재되어 있으나 디지털·신기술 관련 개인정보 처리의 공개 수준은 추가 개선 여지가 있음을 시사한다.

6. 디지털 투명성 vs 정보주체 권리보장

각 업권의 디지털 개인정보 처리 투명성 지표와 정보주체 권리보장 지표를 비교합니다. 버블 크기는 해당 업권의 회사 수를 의미합니다.

디지털 투명성 지표와 권리보장 지표의 관계



6. 주요 인사이트

- 필수항목은 비교적 안정적으로 기재:** required 항목 충족률은 82.0%로 나타났다. 이는 개인정보 처리 목적, 처리 항목, 보유기간, 파기, 보호책임자 등 기본 필수항목은 금융회사 처리방침에 비교적 충실히 기재되어 있음을 의미한다.
- 전체 준수율을 낮추는 요인은 해당 시·권장 항목:** 전체 평균 준수율은 54.5%로 필수항목 충족률보다 낮다. 이는 전체 평가에 conditional, recommended, conditional_recommended 항목이 포함되기 때문이다.
- 디지털·신기술 관련 공개 수준은 상대적으로 낮음:** 국외이전, 가명정보, 제 3 자 행태정보, 자동화된 결정 등 디지털 개인정보 처리 항목은 업권별 편차가 크고 전반적으로 낮은 기재율을 보였다.
- 정보주체 권리보장 항목은 상대적으로 양호:** 권리행사 방법, 보호책임자, 권익침해 구제방법 등 정보주체 권리보장 관련 항목은 디지털 투명성 항목보다 상대적으로 높게 나타났다.
- 조건부 항목은 해석상 주의 필요:** 조건부 항목의 낮은 기재율은 법 위반율이 아니라 공개된 개인정보처리방침상 명시 여부로 해석해야 한다. 실제 해당 개인정보 처리 여부는 별도 확인이 필요하다.

7. Streamlit 대시보드 구현

Streamlit 대시보드는 분석 결과를 쉽게 확인할 수 있도록 메뉴형 구조로 구성하였다. 왼쪽 메뉴를 클릭하면 프로젝트 개요, 핵심 지표, 분석 결과, 회사별 상세 조회, RAG 질의응답, 한계 및 결론 화면으로 이동할 수 있다.

메뉴	주요 기능
프로젝트 개요	연구 질문, 데이터 수집 및 전처리 흐름 설명
핵심 지표	122 개 분석 대상, 24 개 체크리스트, 전체 평균 준수율, 필수항목 충족률 표시
분석 결과	6 개 핵심 EDA 시각화와 해석 제공
회사별 상세 조회	회사별 URL, 업권, 평가 요약, 항목별 상세 평가 제공
RAG 질의응답	로컬 VectorDB 기반 RAG 프로토타입 안내
한계 및 결론	주요 인사이트와 분석 한계 정리

그림 17. Streamlit 프로젝트 개요 화면

DATA MINING PROJECT

금융회사 개인정보처리방침 자동 점검 대시보드

국내 금융회사 홈페이지에 공개된 개인정보처리방침을 수집하고, 개인정보보호위원회 「개인정보 처리방침 작성지침(’26년 4월 24일 기준)」 24개 항목을 기준으로 업권별 기재 수준을 분석한 결과입니다.

분석 전제

본 분석은 공개된 개인정보처리방침에 특정 항목이 명시되어 있는지를 기준으로 합니다. 특히 **해당시 항목**은 실제 해당 개인정보 처리를 수행하는 경우에 기재하는 항목이므로, 미기재를 곧바로 법 위반으로 해석하지 않습니다.

연구 질문

- Q1. 국내 금융회사의 개인정보처리방침은 개인정보보호위원회 작성지침의 주요 기재사항을 얼마나 충족하고 있는가?
- Q2. 금융회사 업권별로 개인정보처리방침 기재 수준에 차이가 있는가?
- Q3. 어떤 작성지침 항목이 가장 자주 누락되거나 낮게 기재되는가?
- Q4. 국외이전, 가명정보, 자동수집장치, 제3자 행태정보, 자동화된 결정 등 디지털-신기술 관련 항목의 공개 수준은 업권별로 어떤 차이를 보이는가?

데이터 수집 및 전처리

최초 수집한 금융회사 개인정보처리방침 PDF를 OCR로 텍스트화한 뒤, 정제 후 텍스트 길이가 1,000자 미만인 문서를 제외하여 최종 분석 표본을 확정했습니다. 또한 데이터 출처의 재현성을 확보하기 위해 금융회사별 개인정보처리방침 URL을 함께 관리했습니다.

단계	문서 수	설명
최초 PDF 수집	130	금융회사 홈페이지에서 Print > PDF 방식으로 수동 저장
OCR 및 텍스트 정제	130	Tesseract OCR 및 정규표현식 기반 노이즈 제거
품질 기준 적용	122	정제 후 텍스트 1,000자 미만 문서 제외
URL 병합	122	185개 URL 마스터에서 최종 분석 대상 122개 URL 병합
최종 분석 대상	122	업권 분류 및 threshold 기반 자동평가 대상 확정

데이터 미리보기

회사별 평가 요약

최종 분석 대상 122개 금융회사의 자동평가 결과 전체를 표시합니다.

company_name	sector	total_score	total_items	compliance_rate	policy_url_sta
KB국민카드	중소서민	20	24	83.3	checked
신한은행	은행	20	24	83.3	checked

requirement_type별 충족률

requirement_type	pass_count	total_count	pass_rate	missing_rate
conditional	558	1464	38.1	61.9
conditional_recommended	5	122	4.1	95.9
recommended	134	244	54.9	45.1

그림 18. 회사별 상세 조회 화면

회사별 상세 조회

특정 회사를 선택하여 24개 체크리스트 항목별 자동평가 결과와 매칭된 키워드, 그리고 실제 개인정보처리방침 수집 URL을 확인합니다.

회사 선택 목록은 총 122개입니다. Streamlit 선택창은 전체 회사를 한 번에 모두 펼쳐 보여주지 않고 일부만 표시합니다. 드롭다운에서 스크롤하거나 회사명을 직접 입력해서 검색할 수 있습니다.

> 전체 회사 목록 보기

회사 선택

AIA생명보험

수집 출처 정보

업권

보험

URL 상태

checked

PDF 파일

AIA생명보험.pdf

개인정보처리방침 URL: <https://www.aia.co.kr/ko/footer/customer-right-information/privacy-policy-guide/pi-processing/20260501.html>

회사 평가 요약

company_name	C01	C02	C03	C04	C05	C06	C07	C08	C09	C10	C11	C12	C13	C14	C15	C16	C17	C18	C19	C20
AIA생명보험	1	1	1	1	1	1	1	0	1	1	0	0	1	1	0	1	0	1	0	1

항목별 상세 평가

항목별 상세 평가 컬럼 설명 보기

컬럼명	설명
item_id	개인정보 처리방침 작성지침을 기준으로 만든 체크리스트 항목 ID입니다. C01부터 C24까지 총 24개 항목입니다.
item_name	체크리스트 항목명입니다. 예: 개인정보의 처리 목적, 개인정보의 제3자 제공, 개인정보 보호책임자 등.
requirement_type	항목의 기재 성격입니다. required는 필수항목, conditional은 해당시 항목, recommended는 권장항목, conditional_recommen
score	자동평가 결과입니다. 1은 해당 항목을 충족한 것으로 판정, 0은 충족하지 못한 것으로 판정했다는 의미입니다.
matched_count	해당 항목의 평가 키워드 중 실제 개인정보처리방침 텍스트에서 발견된 키워드 개수입니다.
min_match_count	해당 항목을 충족으로 판정하기 위해 필요한 최소 키워드 매칭 개수입니다. matched_count가 이 값 이상이면 score가 1이 됩니다
matched_keywords	실제 개인정보처리방침 텍스트에서 발견된 키워드 목록입니다. 자동평가의 근거로 활용됩니다.

예를 들어 matched_count가 3이고 min_match_count가 2이면, 필요한 최소 기준을 넘었기 때문에 score는 1로 판정됩니다. 반대로 matched_count가 1이고 min_match_count가 3이면 score는 0으로 판정됩니다.

item_id	item_name	requirement_type	score	matched_count	min_match_count	matched_keywords
C01	제목 및 서문	required	1	1	1	개인정보처리방침
C02	개인정보의 처리 목적	required	1	3	1	개인정보의처리목적 처리목적 이용목적
C03	처리하는 개인정보의 항목	required	1	2	2	개인정보의항목 수집항목
C04	14세 미만 아동의 개인정보 처리	conditional	1	2	2	14세미만아동 아동의개인정보
C05	개인정보의 처리 및 보유 기간	required	1	5	2	개인정보의처리및보유기간 처리및보유기간 보유기간 이용기간 보유이용기간
C06	개인정보의 파기 절차 및 방법	required	1	3	2	개인정보의파기절차및방법 파기절차 파기방법
C07	개인정보의 제3자 제공	conditional	1	4	3	개인정보의제3자제공 제3자제공 제공받는자 제공목적

8. RAG 질의응답 프로토타입

8.1 RAG 도입 목적

기존 대시보드는 그래프와 표를 통해 사용자가 분석 결과를 직접 확인하는 구조이다.

RAG 질의응답 프로토타입은 사용자가 자연어로 질문하면 관련 개인정보처리방침 문서 조각을 검색하고, OpenAI API 를 통해 근거 기반 답변을 생성하도록 확장한 기능이다.

RAG 기능은 24 개 체크리스트 자동평가 결과를 대체하는 분석 방법이 아니라, 정제된 개인정보처리방침 문서를 자연어로 탐색하기 위한 보조적 확장 기능이다.

8.2 RAG 처리 흐름

정제 텍스트

- 회사별 JSON 변환
- 문서 chunk 분할
- 한국어 문장 임베딩 생성
- ChromaDB VectorDB 저장
- 사용자 자연어 질문 입력
- 관련 chunk 검색
- OpenAI API 기반 답변 생성

8.3 구현 범위

RAG 질의응답 기능은 로컬 환경에서 실행 가능한 프로토타입으로 구현하였다. Streamlit Cloud 배포본에는 VectorDB 파일을 포함하지 않았으며, 배포 안정성을 위해 기본 분석 대시보드 중심으로 제공하였다. RAG 메뉴에서는 Cloud 환경에서 VectorDB 가 없을 경우 로컬 실행 안내 문구를 표시하도록 구성하였다.

따라서 본 프로젝트에서 RAG 는 운영형 서비스가 아니라 로컬 검증용 프로토타입으로 구현하였다. Streamlit Cloud 배포본에서는 기본 분석 대시보드를 안정적으로 제공하고, RAG 메뉴에서는 로컬 실행 안내를 제공하도록 구성하였다.

구분	구현 여부	설명
JSON 변환	구현	정제 텍스트와 평가 결과를 회사별 JSON 으로 구조화
Chunk 생성	구현	긴 개인정보처리방침을 검색 가능한 문서 조각으로 분할
VectorDB 구축	구현	ChromaDB 에 임베딩과 메타데이터 저장
OpenAI API 연동	구현	검색된 근거 기반 자연어 답변 생성
Streamlit Cloud RAG 실행	제한	VectorDB 파일 미포함으로 Cloud 에서는 안내 메시지 제공

그림 19. 로컬 rag_answer.py 실행 결과 화면

로컬 RAG 질의응답 실행 결과, 사용자의 자연어 질문에 대해 VectorDB 에서 관련 개인정보처리방침 문서 조각을 검색하고, OpenAI API 가 이를 바탕으로 근거 기반 답변을 생성하는 것을 확인하였다. 본 기능은 공개 개인정보처리방침상 명시된 내용을 중심으로 답변하도록 설계하였으며, 검색 근거에 없는 내용은 추측하지 않도록 프롬프트를 구성하였다.

```
PS C:\privacy-policy-mining> python src/rag_answer.py
질문을 입력하세요: 은행권에서 국외이전 관련 내용을 설명해줘
Warning: You are sending unauthenticated requests to the HF Hub. Please set a HF_TOKEN to enable higher rate limits and faster downloads.
Loading weights: 100% | 199/199 [00:00<00:00, 18049.57it/s]

[LLM 답변]
=====
1. 결론: 은행권에서 개인정보의 국외이전은 특정 법적 근거에 따라 이루어지며, 고객의 동의가 필요할 수 있습니다. 각 은행의 개인정보처리방침에 따라 구체적인 내용이 다를 수 있습니다.

2. 근거 회사명: 신한은행
3. 근거 chunk 번호: 14
4. 관련 개인정보처리방침 URL: [신한은행 개인정보처리방침](https://www.shinhan.com/hpe/index.jsp#050404040000)
5. 해석상 주의점: 신한은행은 개인정보를 국외의 제3자에게 제공하는 경우에 대한 사항을 명시하고 있으며, 정보주체의 동의 없이 추가적인 이용 및 제공이 가능하다고 설명하고 있습니다. 그러나 구체적인 국외이전의 법적 근거 및 절차는 각 은행의 정책에 따라 다를 수 있으므로, 해당 은행의 개인정보처리방침을 반드시 확인해야 합니다.

추가적으로, KB국민은행의 경우에도 개인정보의 국외이전은 동의에 기반하여 이루어지며, 특정 서비스와 관련하여 필요한 경우에 한정된다고 명시하고 있습니다. 관련 URL은 [KB국민은행 개인정보처리방침](https://obank.kbstar.com/quics?page=C110564)입니다.

[사용 근거]
=====
- 신한은행 / chunk 18 / https://www.shinhan.com/hpe/index.jsp#050404040000
- 신한은행 / chunk 14 / https://www.shinhan.com/hpe/index.jsp#050404040000
- 유진투자증권 / chunk 2 / https://www.eugenefn.com/cskr/cppc/cppc102r.do
- KB국민카드 / chunk 18 / https://card.kbcard.com/SVC/DVIEW/HSEFMXCRSCSC0047
- KB국민은행 / chunk 14 / https://obank.kbstar.com/quics?page=C110564
```

그림 20. Streamlit Cloud RAG 메뉴 안내 화면

Streamlit Cloud 배포본에서는 기본 분석 대시보드의 안정성을 우선 고려하여 VectorDB 파일을 포함하지 않았다. 따라서 RAG 질의응답 메뉴에서는 로컬 환경에서 ChromaDB 기반 VectorDB 를 구축한 후 실행할 수 있다는 안내 문구를 표시하도록 구성하였다. 이는 RAG 기능을 완전한 운영 서비스가 아니라 로컬 검증용 프로토타입으로 구분하기 위한 조치이다.



The image shows a Streamlit application interface for RAG (Retrieval-Augmented Generation). On the left is a sidebar with a 'Privacy Policy' section and a 'Data Mining Project' section. The main area is titled 'RAG 질의응답' (RAG Q&A) and contains a warning box about the local environment, a '질문 입력' (Enter Question) section with a text input and a '질문하기' (Ask Question) button, and a progress bar for the search process.

Privacy Policy
금융회사 개인정보처리방침
자동 점검 및 업권별 기재 수준 분석

Data Mining Project
최종 분석 대상: 122개
체크리스트: 24개 항목

RAG 질의응답
개인정보처리방침 정책 텍스트를 JSON으로 구조화하고, 문서 chunk를 VectorDB에 저장한 뒤, 사용자의 자연어 질문에 대해 관련 문서 조각을 검색하고 LLM이 근거 기반 답변을 생성합니다.

해석 시 주의
RAG 답변은 VectorDB에서 검색된 개인정보처리방침 문서 조각을 기반으로 생성됩니다. 검색 근거에 없는 내용은 확인하기 어렵고, 조건부 항목은 법 위반 여부나 공개 처리방침상 명시 여부로 해석해야 합니다.

질문 입력
예시 질문 선택
직접 입력
질문
예: 은행 업권에서 국외이전 관련 내용을 설명해줘

검색할 근거 문서 조각 수
5

질문하기
질문을 입력하세요.

9. AWS 인프라 구성 및 확장 설계


본 프로젝트는 로컬 Python 환경과 Streamlit Community Cloud 를 기반으로 구현하였다. 향후 운영 환경으로 확장할 경우, AWS 기반 아키텍처를 통해 PDF 저장, OCR/전처리 실행, 분석 결과 저장, VectorDB 검색, LLM 질의응답, 대시보드 제공을 분리하여 구성할 수 있다.

본 절은 실제 AWS 운영 구현 결과가 아니라, 현재 구현한 로컬 분석 및 Streamlit 배포 결과를 AWS 기반 운영 서비스로 확장할 경우의 목표 아키텍처를 제시한 것이다.

구성요소	AWS 서비스 예시	역할
PDF 및 JSON 저장	S3	PDF 원본, JSON 문서, 분석 결과 저장
OCR/전처리 실행	EC2 또는 Lambda	OCR, 텍스트 정제, JSON 변환, chunk 생성
분석 결과 저장	S3 또는 RDS	평가 결과 및 EDA 결과 저장
VectorDB	OpenSearch Vector Engine 또는 RDS PostgreSQL pgvector	문서 임베딩 저장 및 검색
LLM 연동	Amazon Bedrock 또는 OpenAI API	자연어 질의응답 생성
대시보드	Streamlit on EC2 또는 Streamlit Cloud	사용자 화면 제공
모니터링	CloudWatch	실행 로그 및 오류 모니터링

AWS 확장 구조에서는 S3 를 중심으로 PDF 원본과 JSON 문서를 저장하고, EC2 또는 Lambda 에서 OCR 및 전처리 코드를 실행할 수 있다. 정제된 문서는 chunk 단위로 분할한 뒤 embedding 을 생성하여 OpenSearch Vector Engine 또는 RDS PostgreSQL pgvector 에 저장한다. 사용자가 자연어 질문을 입력하면 LLM 이 VectorDB 에서 관련 문서 조각을 검색하고, 검색 근거를 기반으로 답변을 생성하는 RAG 구조로 확장할 수 있다.

그림 21. AWS 기반 확장 아키텍처



10. LDA 이론 소개

10.1 개요

본 절의 LDA는 본 프로젝트에서 실제 모델링 결과를 산출한 분석 단계가 아니라, 교수자 매핑 이론에 따라 개인정보처리방침 분석에 적용 가능한 이론적 확장 방향으로 제시한다.

LDA(Latent Dirichlet Allocation)는 여러 문서 안에 숨어 있는 주제(topic)를 자동으로 찾아내는 대표적인 토픽 모델링 기법이다. 하나의 문서에는 여러 토픽이 섞여 있고, 하나의 토픽은 여러 단어의 확률분포로 구성된다고 가정한다.

10.2 개인정보처리방침 분석과의 연결


개인정보처리방침 하나에는 개인정보 수집·이용 목적, 제 3 자 제공, 위탁, 국외이전, 쿠키·행태정보, 정보주체 권리행사, 보호책임자 등 여러 주제가 함께 포함된다. LDA를 적용하면 122개 금융회사 개인정보처리방침에서 반복적으로 등장하는 숨은 주제를 자동으로 분류하고, 업권별 주요 토픽 비중을 비교할 수 있다.

LDA 토픽 예시	개인정보처리방침 내 의미
Topic 1: 수집·이용 목적	개인정보 수집 목적과 이용 목적 관련 문단
Topic 2: 제 3 자 제공 및 위탁	제공받는 자, 위탁업무, 수탁자 관련 문단
Topic 3: 국외이전 및 클라우드	해외 이전, 국외 처리, 클라우드 관련 문단
Topic 4: 쿠키·행태정보·자동수집장치	쿠키, 접속기록, 행태정보 관련 문단
Topic 5: 정보주체 권리행사 및 보호책임자	권리행사 방법, 보호책임자, 구제방법 관련 문단

체크리스트 기반 평가는 사전에 정한 기준으로 문서를 평가하는 방식이고, LDA는 문서 자체에서 반복적으로 등장하는 주제를 발견하는 방식이다. 두 방법을 함께 사용하면 개인정보처리방침의 준수 수준과 내용상 특징을 동시에 분석할 수 있다.

그림 22. LDA 기반 개인정보처리방침 자동 토픽 분류 개념도

LDA는 여러 개인정보처리방침 문서에 반복적으로 등장하는 단어 패턴을 이용해 숨은 주제(topic)를 자동으로 추정하는 토픽 모델링 기법입니다. 본 프로젝트에서는 122개 금융회사 개인정보처리방침의 내용상 특징을 업권별로 비교하는 확장 분석에 활용할 수 있습니다.



※ 하나의 개인정보처리방침은 하나의 주제로만 구성되지 않고, 수집·이용, 제3자 제공, 위탁, 국외이전, 권리행사 등 여러 토픽이 혼합된 문서로 볼 수 있습니다.

체크리스트 기반 평가는 사전에 정한 기준으로 준수 여부를 판정하고, LDA 토픽 모델링은 문서 자체에서 반복적으로 등장하는 숨은 주제를 발견한다. 두 방법을 함께 사용하면 개인정보처리방침의 준수 수준과 내용상 특징을 동시에 분석할 수 있다.

개인정보처리방침에서 추정 가능한 토픽 예시

Topic 1	수집·이용 목적 예: 수집, 이용, 목적, 서비스, 계약, 회원
Topic 2	제3자 제공 및 위탁 예: 제공, 위탁, 수탁자, 업무, 제공받는 자
Topic 3	국외이전 및 클라우드 예: 국외, 이전, 해외, 보관, 클라우드, 서버
Topic 4	쿠키·행태정보 자동수집장치 예: 쿠키, 접속기록, 행태정보, 자동수집, 거부
Topic 5	정보주체 권리행사 및 보호책임자 예: 열람, 정정, 삭제, 처리정지, 보호책임자, 구제

문서별 토픽 비중 예시

문서	T1 수집	T2 제공	T3 국외	T4 쿠키	T5 권리
은행 A	22%	18%	27%	11%	22%
보험 B	24%	31%	8%	9%	28%
핀테크 C	15%	17%	10%	36%	22%
금융투자 D	21%	24%	16%	13%	26%

※ 수치는 개념 설명용 예시입니다. 실제 분석 시에는 LDA 모델이 문서별 토픽 비중을 확률값으로 산출합니다.

11. 한계 및 향후 개선방안

11.1 분석 한계

- OCR 기반 분석이므로 PDF 품질에 따라 일부 텍스트 추출 오류가 발생할 수 있다.
- 키워드 및 threshold 기반 자동평가는 문맥적 의미를 완전히 반영하지 못할 수 있다.
- 조건부 항목은 실제 해당 개인정보 처리 여부를 별도로 확인해야 하므로, 낮은 기재율을 곧바로 법 위반으로 해석할 수 없다.
- RAG 답변은 VectorDB 에서 검색된 문서 조각을 기반으로 생성되므로, 검색 근거에 없는 내용은 답변할 수 없다.
- Streamlit Cloud 배포본에는 VectorDB 파일을 포함하지 않아 RAG 기능이 제한될 수 있다.

11.2 향후 개선방안

- OCR 품질 개선 및 원문 PDF 페이지 단위 검증 자동화
- LLM 기반 문맥 평가를 활용한 체크리스트 판정 보완
- LDA 또는 BERTopic 기반 개인정보처리방침 토픽 모델링 추가
- AWS S3, OpenSearch Vector Engine, Bedrock 기반 운영형 RAG 구조 확장
- 업권별 표본 수 차이를 고려한 통계적 검정 및 시계열 비교 분석